

Sistema RAG : Ministral vs Qwen

Comparação de LLMs Open-Source em RAG Regulamentar

Avaliação de desempenho e segurança sobre o corpus regulamentar de aeronavegabilidade militar (EMAR).

🎯 Objetivo Estratégico

O objetivo do presente trabalho é a tomada de decisão sobre qual de dois LLMs (Large Language Models) de código aberto é o mais adequado para a implementação de um sistema RAG (Retrieval Augmented Generation) que visa responder a questões sobre a vasta legislação aeronáutica militar, nomeadamente para auditoria de *compliance* interna e chatbots, agilizando o processo de esclarecimento de dúvidas e de consulta de informação e requisitos, contribuindo para um aumento da eficiência operacional.

Foram utilizados no modelo os seguintes documentos de requisitos:

EMAR 21	Conceção e produção de produtos, peças e equipamentos de âmbito militar.	EMAR 66	Licenciamento do pessoal de manutenção, categorias de certificação e requisitos de formação.
EMAR 145	Requisitos para entidades responsáveis pela manutenção de produtos, peças e equipamentos de âmbito militar.	EMAR 147	Requisitos para entidades que ministram formação ao pessoal de certificação de manutenção de aeronaves militares.
EMAR CAMO	Requisitos para organizações de gestão da aeronavegabilidade contínua.	EMAR M	Requisitos relativos à aeronavegabilidade contínua de aeronaves militares.

🔗 Architecture & Stack

Orquestração modular isolada via container Python local com tracking baseado em MLflow.

VECTOR DATABASE
PostgreSQL + pgvector

LOCAL LLM SERVER
LM Studio Local

GUARDRAILS ENGINE
NeMo Guardrails


EVAL & TRACKING
DeepEval + MLflow

🏗️ Arquitetura C4 Nível 1-4: Orquestrador Hybrid Search ReRanker + Local Inference

Pipeline RAG: Ingestão e Retrieval

Diagramas C4

Abaixo é possível seguir os fluxos de **ingestão** e **obtenção de contexto** implementados no Sistema. É também possível ver como os mesmos integram com o resto do sistema nos diagramas C4 disponibilizados como anexos ao projeto (github).



1

Sentence-Aware Chunking

- Janelas de **500 caracteres** com **50 overlap**.
- Respeita limites frásicos para manter integridade semântica.
- Evita fragmentação de cláusulas regulamentares EMAR.



2

Embeddings & pgvector

- Modelo **nomic-embed-text-v1.5** (768 dimensões).
- Indexação híbrida otimizada em PostgreSQL.
- Índices **IVFFlat** (vetorial) + **GIN** (Full-Text Search).



3

Retrieval Híbrido RRF

- Combinação de pesquisa vetorial + busca léxica (FTS).
- Algoritmo **Reciprocal Rank Fusion (RRF)**.
- Maximiza a precisão em termos técnicos aeronáuticos.



4

2-Stage Retrieval

- **Fase 1:** Extração inicial de **500 chunks** candidatos.
- **Fase 2:** Re-ranking refinado para seleção final dos **Top-10**.
- Garante contexto limpo e relevante para a LLM.

Segurança com NeMo Guardrails



Intercepção Pré-Inferência

Filtragem programática executada ao nível do orquestrador antes de atingir a LLM, evitando consumo de VRAM no servidor.



Fluxos Colang Especializados

Políticas estritas para bloqueio de temas fora do âmbito, ilegalidades, toxicidade, documentos classificados e jailbreaks.



Intent Matching & PII Masking

Casamento de intenção via embeddings-only e anonimização automática de dados pessoais.

PII = Personally Identifiable Information



```
# TOXICITY GUARDRAIL (Hate Speech & Insults)
define user express toxic
    "you are stupid"
    "i hate you"
    "you are an idiot"
    "dumb bot"

define bot refuse toxic
    "I will not engage with toxic or abusive language."

define flow toxic
    user express toxic
    bot refuse toxic
    bot stop
```

Avaliação: LLM-as-a-Judge

ANÁLISE CRÍTICA

Pipeline Two-Pass Batched

Fase 1 dedicada à geração do RAG;

Fase 2 isolada para julgamento independente via DeepEval + MLflow.

Evolução do Juiz (**llama-3.2-1B** > **deepseek-r1-0528-qwen3-8b**)

Transição do **llama-3.2-1B** (descartado por alucinações) para um modelo mais robusto na forma do **deepseek-r1-0528-qwen3-8b**.

Insight Técnico Relevante

A métrica determinística léxica (Jaccard Overlap) permitiu identificar e corrigir um bug crítico na propagação da temperatura.

Análise dos datasets obtidos

✓ Guardrails 100% determinísticos

Fora do âmbito (política, injeção de prompts, etc), o Overlap atingiu 1.00, provando que os guardrails interceptam o input antes de chegar à LLM.

✓ Zero alucinações no RAG

Em perguntas militarmente sensíveis, os modelos recusaram responder fora do contexto recuperado (Faithfulness = 1.00), confirmando que o system prompt prioriza a Vector DB sobre o conhecimento pré-treinado.

✓ Overlap lexical não reflete qualidade semântica

Na query sobre CAMO, a Relevancy foi 1.00, mas o Overlap caiu para 0.05–0.09, os modelos geraram respostas mais elaboradas do que o Golden Set, e penalizadas por serem mais verbosas. Justifica o uso de juízes semânticos (DeepEval) em vez de métricas Bag-of-Words.

Modelo	Temp	Faithfulness	Relevancy	Overlap
Ministral-3B	0.0	0,55714	0,61429	0,36461
Ministral-3B	1.0	0,57619	0,62381	0,33617
Ministral-3B	2.0	0,52941	0,60294	0,28935
Qwen-3.5-2B	0.0	0,57619	0,60952	0,34526
Qwen-3.5-2B	1.0	0,60000	0,62857	0,29509
Qwen-3.5-2B	2.0	0,57143	0,61143	0,33923
Modelo	Temp	Faithfulness	Relevancy	Overlap
Ministral-3B	0.0	0,94595	0,67568	0,35520
Ministral-3B	1.0	0,91126	0,68694	0,32174
Ministral-3B	2.0	0,91104	0,64352	0,31276
Qwen-3.5-2B	0.0	0,89352	0,66157	0,34405
Qwen-3.5-2B	1.0	0,77606	0,74093	0,31067
Qwen-3.5-2B	2.0	0,87677	0,70528	0,29856

llama-3.2-1B

deepseek-r1-0528-qwen3-8b

Conclusão e Próximos Passos

GOVERNANÇA & DECISÃO

🔑 Qualidade de Código, Git e Conclusão final

✓ Workflow Git

Feature branches dedicadas, Pull Requests sujeitos a revisão e 3 contribuidores ativos.

✓ Mapeamento C4 Nível 4

Diagramação detalhada da estrutura de código gerada automaticamente via **pyreverse**.

✓ Recomendação de modelo

Qwen-3.5-2B vs Ministral-3B

O Qwen destaca-se em raciocínio dedutivo sobre texto regulatório complexo (ex: distinguiu corretamente ">21 anos" de "<25 anos" no EMAR 66), mas é por vezes excessivamente cauteloso.

O Ministral é mais fluido e conversacional, mas mais rígido em deduções multi-passo.

Decisão final:

Recomenda-se portanto o **Qwen** para auditoria de *compliance* interna (onde a lógica estrita é crítica) e **Ministral** para um chatbot orientado ao utilizador final (onde a fluidez conversacional é prioritária).

🔑 Próximos Passos

→ Garak Red-Teaming

Automação de testes adversariais para deteção profunda e continuada de vulnerabilidades e jailbreaks.

→ Sistema de Prevenção de Intrusões ao Nível da API (Fail2Ban)

Implementação de um bloqueio na API para IPs que atinjam três recusas nos Guardrails, travando o tráfego malicioso antes que este chegue ao modelo.

→ Otimização de Prompts

Implementação de GenAI Prompt Optimizer do MLflow para iterativamente alterar e avaliar prompts, maximizando métricas sem intervenção humana.

[🔗 Repositório](#)<https://github.com/iseg-pg-ai/nlpg-6ed-group-4>